

Relatório Técnico — Systems Privacy Project 1

(Realizado por: Nº 75150)

Metodologia de De-Identificação

A tabela `med_data` continha identificadores diretos: `name`, `address`, `email`, e o identificador da linha.

Para de-identificação, estes atributos foram removidos, criando-se a tabela `med_data_deidentified` com apenas:

- `age`
- `gender`
- `postal_code`
- `diagnosis`

Após correr o `populate_tables.py`, os registos eram:

- `med_data`: 1000 registos
- `med_data_deidentified`: 1000 registos
- `work_data`: 1000 registos

Linkage Attack

O ataque consistiu em tentar re-identificar indivíduos da tabela de saúde de-identificada usando `work_data`, com os seguintes quasi-identifiers:

- `gender`
- `postal_code`

Resultados:

- 805 correspondências diretas entre 1000 registos
- Taxa de sucesso: 80.5%

Interpretação: A de-identificação simples não é suficiente quando existem quasi-identifiers partilhados por bases externas.

K-Anonymity

Quasi-identifiers e Sensitive Attribute:

- Quasi-identifiers: `age`, `gender`, `postal_code`
- Sensitive: `diagnosis`

Algoritmo:

- Generalização e agrupamento por equivalence classes $\geq k$.
- Generalizações aplicadas:
 - Age: intervalos de 10 anos (ex.: 20–29, 30–39)
 - Gender: mantido

- Postal Code: primeiros 3 dígitos mantidos

Validação:

- Antes da generalização, várias combinações tinham count = 1, mostrando vulnerabilidade.
- Após K-Anonymity, todas as equivalence classes tinham tamanho $\geq k$, reduzindo drasticamente a possibilidade de linkage attack.

Linkage Attack pós K-Anonymity:

- Correspondências diretas diminuíram para 0, evidenciando a eficácia da anonimização.

Trade-off: Maior privacidade = menor precisão das análises.

Differential Privacy

Endpoints implementados:

- /api/dp/count
- /api/dp/average
- /api/dp/group (histogram/grouped count)

Configuração:

- Epsilon (ϵ): configurável em application.properties (ex.: dp.epsilon=1.0)
- Sensibilidade (Δf):
 - Count: 1
 - Average: $(\max - \min) / N \approx 0.108$
 - Grouped Count: 1 por grupo

Mecanismo:

- Laplace Mechanism:

$$\text{noisy_value} = \text{true_value} + \text{Laplace}(\Delta f / \epsilon)$$

- Cada query consome ϵ do privacy budget.
- Quando o orçamento esgota, retorna HTTP 404.

Resultados (valores reais):

Count Query:

POST /api/dp/count

{ "attribute": "diagnosis" }

- Resultado com ruído: -1.6992521488103045
- Sensibilidade: 1

- Budget restante: 9/10 ε

Average Query:

POST /api/dp/average

{ "attribute": "age" }

- Resultado com ruído: 49.196879701134286 anos
- Sensibilidade: 0.108
- Budget restante: 8/10 ε

Grouped Count Query:

POST /api/dp/group

{ "attribute": "diagnosis" }

- Resultado com ruído: 1035.6100125598057
- Sensibilidade: 1 por grupo
- Budget restante: 7/10 ε

Observação: Estes valores ilustram a proteção conferida pelo ruído, mantendo utilidade estatística agregada.

Resultados e Discussão

- De-identificação simples: mantém todos os dados úteis, mas vulnerável a linkage (80.5% sucesso).
- K-Anonymity: protege contra linkage; perde-se precisão devido à generalização.
- Differential Privacy: garante privacidade forte mesmo com dados externos, mantendo análises estatísticas confiáveis.

Conclusões

- De-identificação simples não basta; linkage attack mostrou alta taxa de re-identificação.
- K-Anonymity aumenta a privacidade e impede linkage, mas reduz utilidade (granularidade perdida).
- Differential Privacy combina privacidade e utilidade, ideal para queries agregadas.
- O projeto demonstrou na prática os trade-offs de cada técnica e confirmou os resultados dos testes reais.